

TEORIA

-1-

$X = (X_1 \dots X_p)^T$ - wektor losowy

$\mu^X = (EX_1 \dots EX_p)^T$ - wektor wartości oczekiwanych

$$\Sigma^X(i, j) = \text{cov}(X_i, X_j) = E(X_i X_j) - EX_i EX_j$$

Właściwości cov:

1. $\Sigma^X(i, j) = \Sigma^X(j, i)$

/ $\text{cov}(X_i, X_j) = \text{cov}(X_j, X_i)$ /
(symetryczność)

2. $\text{cov}(\alpha X_i + \beta X_j, X_k) = \alpha \text{cov}(X_i, X_k) + \beta \text{cov}(X_j, X_k)$
(liniowość na każdym argumentcie)

3. $\Sigma^X(i, i) = \text{cov}(X_i, X_i) = EX_i^2 - (EX_i)^2 =$
 $= \text{VAR } X_i \geq 0.$
(nieujemność)

$$\Sigma_{p \times p}^X = \left(\Sigma^X(i, j) \right)_{i, j=1}^p ; \Sigma^X = \Sigma_{p \times p}^X$$

$$\Sigma_{p \times p}^X = \begin{pmatrix} \text{Var } X_1 & \dots & \text{cov}(X_1, X_p) \\ \vdots & \ddots & \vdots \\ \text{cov}(X_p, X_1) & \dots & \text{Var } X_p \end{pmatrix} \quad \text{macierz kowariancji}$$

Właściwości $\Sigma_{p \times p}^X$:

1. symetryczność $\left(\left(\Sigma_{p \times p}^X \right)^T = \Sigma_{p \times p}^X \right)$

2. wszystkie elementy na głównej przekątnej ≥ 0 .

3. Σ^x jest diagonalna -2-

4. $\Leftrightarrow X_1 \dots X_p$ są nieskorelowane $\left(\begin{smallmatrix} X_1 \dots X_p \text{ - norm} \\ \text{niezależny} \end{smallmatrix} \right)$
 Σ^x - nieujemnie określona

(Forma kwadratowa: $\sum_{i,j=1}^p \Sigma(a_{ij}) X_i X_j \geq 0$
 \Leftrightarrow wartości własne ≥ 0
 Kryterium Sylwestera +)

Przykład:

ξ_1, ξ_2, ξ_3 - zmienne losowe, niezależne
 $\text{var } \xi_i = \sigma_i^2$

$$X_1 = a_1 \xi_1 + a_2 \xi_2 + a_3 \xi_3$$

$$X_2 = b_1 \xi_1 + b_2 \xi_2 + b_3 \xi_3$$

$$X_3 = c_1 \xi_1 + c_2 \xi_2 + c_3 \xi_3$$

$$a_i, b_i, c_i \in \mathbb{R}$$

$$\text{cov}(X_1, X_1) = \text{var } X_1 \xrightarrow{\xi_i \text{ - niez.}} a_1^2 \text{var } \xi_1 + a_2^2 \text{var } \xi_2 + a_3^2 \text{var } \xi_3 = \sum_{i=1}^3 a_i^2 \sigma_i^2$$

$$\text{cov}(X_1, X_2) = \text{cov}(a_1 \xi_1 + a_2 \xi_2 + a_3 \xi_3, b_1 \xi_1 + b_2 \xi_2 + b_3 \xi_3) = \text{likiowość cov} = \text{niezal.}$$

$$= a_1 b_1 \text{cov}(\xi_1, \xi_1) + a_1 b_2 \text{cov}(\xi_1, \xi_2) + \dots + a_3 b_3 \text{cov}(\xi_3, \xi_3) = 0$$

$\text{var } \xi_3 = \sigma_3^2$

$$= a_1 b_1 \sigma_1^2 + a_2 b_2 \sigma_2^2 + a_3 b_3 \sigma_3^2 = \sum_{i=1}^3 a_i b_i \sigma_i^2$$

$$\Sigma_{3 \times 3}^x = \begin{pmatrix} \sum a_i^2 \sigma_i^2 & \sum a_i b_i \sigma_i^2 & \sum a_i c_i \sigma_i^2 \\ - & \sum b_i^2 \sigma_i^2 & \sum b_i c_i \sigma_i^2 \\ - & - & \sum c_i^2 \sigma_i^2 \end{pmatrix}$$

$$X = (X_1 \dots X_p) \text{ w.l.}$$

μ^X - wektor wartości oczekiwanych

$\Sigma^X_{p \times p}$ - macierz kowariancji

-3-

Dla dowolnej ustalonej macierzy

$A = A_{k \times p}$ i wektora $B \in \mathbb{R}^k$:

definiujemy przekształcenie liniowe:
całkowitej

$$Y = AX + B$$

$$Y = (y_1 \dots y_k)$$

$$\Rightarrow \mu^Y = A \mu^X + B$$

$$\Sigma^Y = A \Sigma^X A^T$$

$$k \times p \quad p \times p \quad p \times k$$

$$\Sigma^Y = \Sigma^Y_{k \times k}$$

/ dowód: ~~przez~~ liniowość przekształcenia;
 $E, \text{cov}(\dots, \dots)$ /

Przykład:

$$\xi = (\xi_1, \xi_2, \xi_3)^T$$

$$\mu^\xi = (E\xi_1, E\xi_2, E\xi_3)^T$$

$$\Sigma^\xi = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix}$$

$$A = \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix}$$

$$X = (X_1, X_2, X_3)^T$$

$$\Rightarrow X = A\xi$$

$$\begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix} = \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix} \begin{pmatrix} \xi_1 \\ \xi_2 \\ \xi_3 \end{pmatrix}$$

$$\Rightarrow \mu^X = A \mu^\xi;$$

$$\Sigma^X = A \Sigma^Z A^T =$$

$$= \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix} \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix} \begin{pmatrix} a_1 & b_1 & c_1 \\ a_2 & b_2 & c_2 \\ a_3 & b_3 & c_3 \end{pmatrix} =$$

$$= \dots$$

Wielowymiarowy rozkład normalny:
 $N(\mu, \Sigma)$.

$X \sim N(\mu, \Sigma) \Leftrightarrow$ gęstość wyraża się wzorem:

$$f(x) = \det(2\pi\Sigma)^{-1/2} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)$$

$$x = (x_1, \dots, x_p)^T; \quad \mu = (\mu_1, \dots, \mu_p)$$

$$\Sigma^{-1} = (\tilde{\sigma}_{ij})_{i,j=1}^p$$

$$(x-\mu)^T \Sigma^{-1} (x-\mu) = \sum \tilde{\sigma}_{ij} (x_i - \mu_i)(x_j - \mu_j)$$

(forma kwadratowa)

Przykład

$$X = (x_1, \dots, x_p) \quad x_i - \text{niezależne} \sim N(0,1)$$

$$\Leftrightarrow \Sigma = I \quad (\text{jednostkowa})$$

$$\Rightarrow \Sigma^{-1} = I$$

$$\mu^X = (0, \dots, 0)$$

$$\Rightarrow (x-\mu)^T \Sigma^{-1} (x-\mu) = \sum x_i^2$$

$$X \sim N(\vec{0}, I) \Leftrightarrow f(x) = (2\pi)^{-\frac{p}{2}} e^{-\frac{1}{2}(x_1^2 + \dots + x_p^2)}$$

$$X \sim N(\mu, \Sigma)$$

-5-

$$Y = AX + B, \quad A = A_{k \times p}; \quad B \in \mathbb{R}^k$$

$$Y = (Y_1 \dots Y_k)$$

$$\Rightarrow Y \sim N(A\mu + B, A\Sigma A^T)$$

Pytanie

$X \sim N(\mu, \Sigma)$ jak wygenerować?

$$\mu = (\mu_1 \dots \mu_p)^T; \quad \Sigma = \Sigma_{p \times p}$$

I krok

$$\xi = (\xi_1 \dots \xi_p)^T$$

ξ_i - niezależne
 $N(0, 1)$

/znorm (1) p razy/
znorm (p)

$$\xi \sim N(\vec{0}, I)$$

II krok

wybieramy: $A, B: \quad X = A\xi + B$

$$X \sim N(B, AA^T) = N(\mu, \Sigma)$$

$$\mu = B$$

$$\Sigma = AA^T, \quad (A \text{ nie jest jednoznacznie zdefiniowane})$$

A - dolna macierz trójkątna
Rozkład Choleskiego

$$\begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{21} & \dots & a_{p1} \\ a_{21} & a_{22} & \dots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p1} & a_{p2} & \dots & a_{pp} \end{pmatrix} \begin{pmatrix} a_{11} & a_{21} & \dots & a_{p1} \\ a_{22} & \dots & \dots & a_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{pp} & \dots & \dots & a_{pp} \end{pmatrix}$$

$$\sigma_{11} = a_{11}^2 \Rightarrow a_{11} = \sqrt{\sigma_{11}}$$

$$\sigma_{12} = \sigma_{21} = a_{21} a_{11} \Rightarrow a_{21} = \frac{\sigma_{21}}{a_{11}}$$

$$\sigma_{22} = a_{21}^2 + a_{22}^2 \Rightarrow a_{22} = \sqrt{\sigma_{22} - a_{21}^2}$$

...

$$a_{ii} = \sqrt{\sigma_{ii} - \sum_{k=1}^{i-1} a_{ik}^2}$$

$$a_{ij} = \frac{\sigma_{ij} - \sum_{k=1}^{i-1} a_{jk} a_{ik}}{a_{ii}}$$

Przykład:

$$\mu = (1, 1, 1)^T, \quad \Sigma = \begin{pmatrix} 4 & 1 & 2 \\ 1 & 9 & 3 \\ 2 & 3 & 4 \end{pmatrix}$$

wygenerować $X \sim N(\mu, \Sigma)$

$$I: \quad \xi = (\xi_1, \xi_2, \xi_3) \quad \xi_i - \text{niezależne} \sim N(0, 1)$$

$$X = A\xi + B; \quad B = (1, 1, 1)^T$$

$$A: \quad \Sigma = A A^T$$

$$\begin{pmatrix} 4 & 1 & 2 \\ 1 & 9 & 3 \\ 2 & 3 & 4 \end{pmatrix} = \begin{pmatrix} a_{11} & 0 & 0 \\ a_{21} & a_{22} & 0 \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \begin{pmatrix} a_{11} & a_{21} & a_{31} \\ 0 & a_{22} & a_{32} \\ 0 & 0 & a_{33} \end{pmatrix}$$

$$a_{11} = 2$$

$$\sigma_{21} = 1 = a_{21} \cdot a_{11} \Rightarrow a_{21} = \frac{1}{2}$$

$$\sigma_{22} = 9 = a_{21}^2 + a_{22}^2 \Rightarrow a_{22}^2 = 9 - \frac{1}{4} = \frac{35}{4}; \quad a_{22} = \frac{\sqrt{35}}{2}$$

$$\tilde{\sigma}_{31} = 2 = a_{31} a_{11} \Rightarrow a_{31} = 1$$

$$\sigma_{32} = 3 = a_{31} a_{21} + a_{32} a_{22} = \frac{1}{2} + a_{32} \frac{\sqrt{35}}{2}$$

$$\Rightarrow a_{32} = \frac{5}{\sqrt{35}} = \frac{\sqrt{5}}{\sqrt{7}}$$

$$\tilde{\sigma}_{33} = 4 = a_{31}^2 + a_{32}^2 + a_{33}^2 = 1 + \frac{5}{7} + a_{33}^2 \Rightarrow a_{33} = \frac{4}{\sqrt{7}}$$

$$A = \begin{pmatrix} 2 & 0 & 0 \\ \frac{1}{2} & \frac{\sqrt{35}}{2} & 0 \\ 1 & \frac{\sqrt{5}}{\sqrt{7}} & \frac{4}{\sqrt{7}} \end{pmatrix}$$

$$X = A\zeta + B$$