

### Zadanie 1

Rozważamy model:  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$

Estymatory  $\beta_0, \beta_1, \beta_2, \sigma$  wynoszą  $b_0 = 1, b_1 = 4, b_2 = 3, s = 3$

Dokonamy predykcji dla wartości  $X_1 = 2, X_2 = 6$ :

$$\hat{Y} = 1 + 4 \cdot 2 + 3 \cdot 6 = 27$$

W drugim kroku będziemy estymować wartość wariancji błędu predykcji  $Y_h$ , przy założeniu, że standardowe odchylenie estymatora wartości oczekiwanej  $Y_h$  wynosi 2, tj.  $\hat{\mu}_h = 2$ , dla  $X_1, X_2$  takich jak w poprzednim punkcie. Otrzymujemy:

$$s^2(pred) = s^2 + s^2(\hat{\mu}_h) = 9 + 4 = 13.$$

Założmy, że nasz model został wytrenowany na 20 obserwacjach, a standardowe odchylenie  $b_1, s(b_1)$ , wynosi 1. Skonstruuj 95% przedział ufności dla  $\beta_1$ .

Jest on dany wzorem:  $b_1 \pm t_c s(b_1)$ , gdzie  $t_c$  jest kwantylem rzędu 0.95 z rozkładu studenta z 17 stopniami swobody. Korzystając z funkcji  $qt$  w *R*, otrzymujemy, że jest on w przybliżeniu równy 2.1. Otrzymujemy przedział ufności postaci (1.9, 6.1).

### Zadanie 2

Analizujemy dane korzystając z modelu  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ .

Mamy dane sumy typu I i II:

	Typ I	Typ II
$X_1$	300	30
$X_2$	40	25
$X_3$	20	?

Oraz zakładamy, że  $SST = 760, n = 24$ .

W pierwszym kroku wyznaczmy sumę typu II dla  $X_3$ . Z definicji, jest ona równa  $SSM(X_3|X_1, X_2)$ , co jest równe sumie typu I dla  $X_3$ , a więc wynosi ona 20.

W drugim kroku zbadamy istotność regresora  $X_1$ . Porównamy modele:

$H_0$  : dane pochodzą z modelu  $Y = \beta_0 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ .

$H_1$  : dane pochodzą z modelu  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ .

Statystyka testowa  $F$  wynosi 
$$\frac{(SSE(R) - SSE(F))/(dfE(R) - dfE(F))}{MSE(F)} = \frac{SSM(X_1|X_2, X_3)}{MSE(F)}$$

Z tabeli odczytujemy, że  $SSM(X_1|X_2, X_3) = 30$ .

Wiemy, że  $MSE(F) = SSE(F)/dfE(F)$ .  $dfE(F)$  wynosi  $24 - 4 = 20$ , natomiast  $SSE(F) = SST - SSM = 760 - 300 - 40 - 20 = 400$ .

$$\text{Otrzymujemy } F = \frac{30}{400/20} = 1.5$$

Przy użyciu *R*, obliczę  $F^*$ , czyli kwantyl rzędu 0.95 z rozkładu Fischera-Snedecora o 1, 20 stopniach swobody. Wynosi on 4.35, a więc jest znacznie większy od statystyki testowej  $F$ , co oznacza, że nie możemy odrzucić hipotezy  $H_0 : \beta_1 = 0$ .

W trzecim podpunkcie, przetestuję hipotezę  $\beta_2 = 0, \beta_3 = 0$ . Analogicznie jak w poprzednim kroku, porównam modele:

$H_0$  : dane pochodzą z modelu  $Y = \beta_0 + \beta_1 X_1 + \epsilon$ .

$H_1$  : dane pochodzą z modelu  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ .

$$SSE(R) - SSE(F) = SSM(F) - SSM(R) = SSM(X_1, X_2, X_3) - SSM(X_1) = 60.$$

Otrzymujemy  $F = \frac{60/2}{20} = 1.5$ . Wartość  $F^*$  (z rozkładu Fischera-Snedecora o 2, 20 stopniach swobody), wynosi 3.49, więc ponownie jest ona wyższa od  $F$ , przez co nie możemy odrzucić hipotezy  $\beta_2 = \beta_3 = 0$

W kolejnym kroku przetestuję hipotezę  $\beta_1 = \beta_2 = \beta_3 = 0$ , czyli porównam modele:

$H_0$  : dane pochodzą z modelu  $Y = \beta_0 + \epsilon$ .

$H_1$  : dane pochodzą z modelu  $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$ .

Statystyka testowa  $F$  wynosi  $\frac{360/3}{20} = 6$

Kwantyl rzędu 0.95 z rozkładu Fishera-Snedecora o 3, 20 stopniach swobody wyniósł  $F^* = 3.09$ , co jest mniejsze od  $F$ . Możemy więc odrzucić hipotezę, że  $\beta_1 = \beta_2 = \beta_3 = 0$ .

W przedostatnim kroku, odrzucę zmienne  $X_2, X_3$  i zbadać hipotezę:

$H_0 : \beta_1 = 0$  vs  $H_1 : \beta_1 \neq 0$ .

Statystyka testowa wynosi  $F = \frac{MSM}{MSE} = \frac{dfE \cdot SSM}{dfM \cdot SSE} = \frac{22 \cdot SSM}{1 \cdot SSE} = \frac{22 \cdot 30}{760 - 30} = 0.9$

Kwantyl rzędu 0.95 z rozkładu Fishera-Snedecora o 1, 22 stopniach swobody wynosi 4.3, co jest większe od  $F$ , więc nie możemy odrzucić hipotezy  $H_0 : \beta_1 = 0$

W ostatnim podpunkcie, policzymy korelację próbkową pomiędzy  $Y$  a  $X_1$ . Skorzystam z faktu, że współczynnik determinacji  $R^2$  jest kwadratem korelacji próbkowej.

$$R^2 = \frac{SSM(X_1|X_2, X_3)}{SSM(X_1|X_2, X_3) + SSE(F)} = \frac{30}{430} \approx 0.069$$

Otrzymujemy, że korelacja próbkowa jest w przybliżeniu równa  $\pm 0.26$