

# Modele liniowe

Michał Kos

Uniwersytet Wrocławski

# Plan wykładu

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne

# Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne

# Regresja liniowa wieloraka

Pomysł zawarty w regresji liniowej prostej można łatwo uogólnić na sytuację w której zmiennych objaśniających jest więcej niż jedna. Wówczas z każdą wartością zmiennej odpowiedzi  $Y_i$  stowarzyszony jest wektor wartości kilku regresorów  $X_i = (X_{i1}, \dots, X_{ip-1})'$ :

## Model teoretyczny regresji liniowej wielorakiej w postaci skalarnej

Teoretyczny model dla regresji liniowej wielorakiej:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \dots + X_{ip-1}\beta_{p-1} + \epsilon_i \quad i = 1, \dots, n$$

gdzie:  $\epsilon_1, \dots, \epsilon_n$  – błędy losowe, ciąg niezależnych zmiennych losowych z rozkładu normalnego o średniej 0 i wariancji  $\sigma^2$

$X_{ij}$  – wartość j-tej zmiennej niezależnej stowarzyszona z i-tą obserwacją zmiennej zależnej  $Y_i$ ,

$\beta_0$  – Intercept,

$\beta_k \quad k = 1, \dots, p - 1$  – parametry regresji związane z odpowiadającymi im zmiennymi objaśniającymi ("Slope"-y).

# Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

# Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

## Przykład 1

Badania medyczne wskazują na to, że ciśnienie pacjenta  $Y_i$  zależy od wielu czynników np. wiek, BMI, przewlekłe stany chorobowe, pula genetyczna  $X_i = (X_{i1}, \dots, X_{ip-1})'$ .

# Regresja liniowa wieloraka – ważne przykłady

Łatwo zauważyć, że takie uogólnienie jest mocno pożądane. Zwykle badacz podejrzewa, że na badane zjawisko ma wpływ więcej niż jedna cecha.

## Przykład 1

Badania medyczne wskazują na to, że ciśnienie pacjenta  $Y_i$  zależy od wielu czynników np. wiek, BMI, przewlekłe stany chorobowe, pula genetyczna  $X_i = (X_{i1}, \dots, X_{ip-1})'$ .

Stosowanie regresji liniowej wielorakiej umożliwia równoczesną analizę wpływu kilku cech. Ponadto, (przy odpowiedniej wstępnej obróbce danych) daje możliwość porównywania siły poszczególnych cech.

# Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Regresja liniowa wieloraka pozwala na modelowanie relacji nieliniowych.



# Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Regresja liniowa wieloraka pozwala na modelowanie relacji nieliniowych.

## Przykład 2

Z fizyki wiemy, że przemieszczenie w swobodnym spadku w polu grawitacyjnym ziemi wyraża się następującym wzorem:

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

gdzie:  $\beta_0$  – początkowe położenie ciała,  $\beta_1$  – początkowa szybkość ciała (w kierunku  $y$ ),  $\beta_2 = -\frac{g}{2}$   $g$  – przyspieszenie ziemskie,  $t$  – czas,  $Y(t)$  – położenie w chwili  $t$ .

Powyższa relacja w oczywisty sposób jest funkcją kwadratową. W związku z tym dla par obserwacji  $\{(Y_i, t_i)\}_{i=1}^n$  model uzyskany przy użyciu regresji liniowej prostej (dopasowujący prostą do danych;  $\hat{Y}_i = \hat{\beta}_0 + t_i\hat{\beta}_1$ ) będzie nieadekwatny.

# Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Przykład 2 c.d.

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

Jednakże, alternatywnie, do zbioru danych  $\{(Y_i, t_i)\}_{i=1}^n$  możemy użyć modelu regresji wielorakiej następującej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i$$

gdzie  $X_{i1} = t_i$ ,  $X_{i2} = t_i^2$ , oraz  $\epsilon_i$  – błąd związany z pomiarem położenia ciała ( $Y_i$ ) w chwili  $t_i$ .

# Regresja liniowa wieloraka – ważne przykłady (relacje nieliniowe)

Przykład 2 c.d.

$$Y(t) = \beta_0 + t\beta_1 + t^2\beta_2$$

Jednakże, alternatywnie, do zbioru danych  $\{(Y_i, t_i)\}_{i=1}^n$  możemy użyć modelu regresji wielorakiej następującej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i$$

gdzie  $X_{i1} = t_i$ ,  $X_{i2} = t_i^2$ , oraz  $\epsilon_i$  – błąd związany z pomiarem położenia ciała ( $Y_i$ ) w chwili  $t_i$ .

Powyższy model umożliwia dopasowanie funkcji kwadratowej do danych. Stosując analogiczne rozumowanie możemy dopasować do danych np. wielomian dowolnego stopnia lub inne nieliniowe relacje.

# Regresja liniowa wieloraka – ważne przykłady (interakcja)

Czasami naturalnym wydaje się, że równoczesne występowanie kilku czynników ma dodatkowy pozytywny wpływ na zmienną odpowiedzi  $Y$ .

# Regresja liniowa wieloraka – ważne przykłady (interakcja)

Czasami naturalnym wydaje się, że równoczesne występowanie kilku czynników ma dodatkowy pozytywny wpływ na zmienną odpowiedzi  $Y$ .

## Przykład 3

Na zbiory rolnicze ( $Y$ ) ma wpływ np. skład podłoża (np. nawóz) oraz odpowiednie nawodnienie. Możemy zatem zastosować następujący model:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

gdzie  $X_{i1}$  – zmienna niezależna będąca indykatorem opisującym to czy na polu  $Y_i$  zastosowano nawóz ( $X_{i1} = 1$ ) czy nie zastosowano nawożenia ( $X_{i1} = 0$ ),

$X_{i2}$  – zmienna niezależna opisując poziom nawodnienia obszaru  $Y_i$  np. ilość wody na  $m^2$  w jednostce czasu.

# Regresja liniowa wieloraka – ważne przykłady (interakcja)

Przykład 3 c.d.

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

Zgodnie z powyższym modelem zysk dla każdego czynnika (nawożenie, nawadnianie) jest niezależny. Wydaje się jednak, że równoczesne zastosowanie optymalnych nawozu i nawodnienia może skutkować pewnym "bonusowym" plonem ("1+1 = 5").

# Regresja liniowa wieloraka – ważne przykłady (interakcja)

Przykład 3 c.d.

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \epsilon_i \quad i = 1, \dots, n$$

Zgodnie z powyższym modelem zysk dla każdego czynnika (nawożenie, nawadnianie) jest niezależny. Wydaje się jednak, że równoczesne zastosowanie optymalnych nawozu i nawodnienia może skutkować pewnym "bonusowym" plonem ("1+1 = 5").

Powyższą obserwację możemy uwzględnić wykorzystując tzw. model liniowy z interakcjami:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + X_{i1}X_{i2}\beta_3 + \epsilon_i \quad i = 1, \dots, n$$

W powyższym modelu składnik  $X_{i1}X_{i2}\beta_3$  opisuje "bonusowy" wpływ interakcji pomiędzy zmiennymi  $X_{i1}$  i  $X_{i2}$ . Wprowadzając oznaczenie  $X_{i3} = X_{i1}X_{i2}$  otrzymujemy model regresji liniowej wielorakiej postaci:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + X_{i3}\beta_3 + \epsilon_i \quad i = 1, \dots, n$$

# Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy**
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne



# Model teoretyczny w postaci skalarnej

## Model teoretyczny w postaci skalarnej

Poznaliśmy już teoretyczny model dla regresji liniowej w zapisie skalarnym:

$$Y_i = \beta_0 + X_{i1}\beta_1 + X_{i2}\beta_2 + \dots + X_{ip-1}\beta_{p-1} + \epsilon_i \quad i = 1, \dots, n$$

gdzie  $\epsilon_1, \dots, \epsilon_n$  – ciąg niezależnych zmiennych losowych z rozkładu normalnego o średniej 0 i wariancji  $\sigma^2$ .

Model ten bardzo często zapisywany jest alternatywnie w postaci macierzowej:

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

# Model teoretyczny w postaci macierzowej – oznaczenia

Wprowadźmy następujące oznaczenia:

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}; \quad \mathbb{X} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix}$$
$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix}; \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

gdzie:

$Y \in \mathbb{R}^n$  nazywamy wektorem odpowiedzi,

$\mathbb{X} \in M_{n \times p}$  nazywamy macierzą planu lub eksperymentu (deterministyczna macierz),

$\beta \in \mathbb{R}^p$  nazywamy wektorem parametrów (deterministyczny wektor),

$\epsilon \in \mathbb{R}^n$  nazywamy wektorem błędów losowych.

# Model teoretyczny w postaci macierzowej

## Model teoretyczny w postaci macierzowej

Model teoretyczny dla regresji liniowej wielorakiej w zapisie macierzowym ma postać:

$$Y = \mathbb{X}\beta + \epsilon$$

gdzie  $\epsilon \in \mathbb{R}^n$  jest wektorem losowym z rozkładu normalnego  $N(0_n, \sigma^2 \mathbb{I}_n)$ .

# Model teoretyczny w postaci macierzowej

## Model teoretyczny w postaci macierzowej

Model teoretyczny dla regresji liniowej wielorakiej w zapisie macierzowym ma postać:

$$Y = X\beta + \epsilon$$

gdzie  $\epsilon \in \mathbb{R}^n$  jest wektorem losowym z rozkładu normalnego  $N(0_n, \sigma^2 \mathbb{I}_n)$ .

Ma on zatem dokładnie tę samą postać co teoretyczny model regresji liniowej prostej. Jedyną różnicą jest liczba kolumn w macierzy planu  $X$  i liczba parametrów w wektorze  $\beta$ :

równanie		$Y$	$=$	$X$	$\beta$	$+$	$\epsilon$
wymiary (macierzowo)		$n \times 1$		$n \times p$	$p \times 1$		$n \times 1$

## Uwaga o notacji w wektorze $\beta$ i macierzy $\mathbb{X}$

W wektorze  $\beta = (\beta_0, \beta_1, \dots, \beta_{p-1})'$  jest  $p$  elementów, przy czym numerujemy je od 0 do  $p - 1$ , zachowując "wyjątkowość" parametru  $\beta_0$  jako interceptu. Pozostałe  $p - 1$  elementów opisuje wpływ poszczególnych regresorów.

Podobnie w macierzy planu  $\mathbb{X}$  jest  $p$  kolumn. Pierwsza kolumna to ciąg jedynek ( $\forall i$ )  $\mathbb{X}_{i1} = 1$  stowarzyszony z Interceptem. Kolejne kolumny opisują zachowanie poszczególnych zmiennych niezależnych dla kolejnych obserwacji ( $\forall i, j \geq 2$ )  $\mathbb{X}_{ij} = X_{ij-1}$

$$\mathbb{X} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np-1} \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{pmatrix};$$

## Tw. 1

Jeżeli  $B = c + DA \in \mathbb{R}^m$ , jest afinicznym przekształceniem wektora losowego  $A \sim N(\mu, \Sigma) \in \mathbb{R}^n$ , gdzie  $c \in \mathbb{R}^m$  jest deterministycznym wektorem oraz  $D \in \mathbb{M}_{m \times n}$  jest deterministyczną macierzą, wówczas:

$$B \sim N(c + D\mu, D\Sigma D')$$

Na podstawie Tw. 1 otrzymujemy w natychmiastowy sposób że:

$$Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$$

Czyli:

- ① Wektor  $Y$  pochodzi z  $n$ -wymiarowego rozkładu normalnego,
- ② Wartość oczekiwana jest liniowym przekształceniem:  $E(Y) = \mathbb{X}\beta$ ,
- ③ Macierz kowariancji jest postaci:  $\text{Cov}(Y) = \sigma^2\mathbb{I}$ :
  - $Y_1, \dots, Y_n$  jest ciągiem niezależnych zmiennych losowych o stałej wariancji  $\sigma^2$ .

# Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji**
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne

# Metoda najmniejszych kwadratów

Kryterium estymacji parametrów metodą najmniejszych kwadratów w regresji liniowej wielorakiej:

$$\hat{\beta} = \arg \min_b \sum_{i=1}^n (Y_i - (b_0 + X_{i1}b_1 + \dots + X_{ip-1}b_{p-1}))^2 = \arg \min_b \sum_{i=1}^n e_i^2(b)$$

gdzie  $b = (b_0, b_1, \dots, b_{p-1})' \in \mathbb{R}^p$ ,  $e_i(b)$  – ciąg residuów stowarzyszony z wektorem  $b$ .

W notacji macierzowej możemy zapisać powyższe równanie w następującej postaci:

$$\hat{\beta} = \arg \min_b \|Y - \mathbb{X}b\|_2^2 = \arg \min_b \|e(b)\|_2^2$$

## Residua dla estymatora OLS

W przypadku estymatora najmniejszych kwadratów we wzorze na residuum (wektor residuów) będziemy pomijać argument funkcji:

$$e_i := e_i(\hat{\beta}); \quad e := e(\hat{\beta})$$



# Estymator metody najmniejszych kwadratów (1)

Zapis macierzowy umożliwia elegancki sposób wyrażenia estymatora metody najmniejszych kwadratów. Wyznamy pochodną z funkcji  $\|Y - \mathbb{X}b\|_2^2$  po współczynnikach:

$$\begin{aligned}\partial_{b_0} \|Y - \mathbb{X}b\|_2^2 &= \partial_{b_0} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 = \\ &= \sum_{i=1}^n -2\mathbb{X}_{i1}(Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1})) = \\ &= -2\mathbb{X}'_{\bullet 1}(Y - \mathbb{X}b) = -2\mathbb{X}'_{\bullet 1}e(b)\end{aligned}$$

gdzie  $\mathbb{X}_{\bullet j}$  oznacza  $j$ -tą kolumnę w macierzy  $\mathbb{X}$ .

## Estymator metody najmniejszych kwadratów (2)

W analogiczny sposób można uzyskać pochodną po dowolnym  $b_i$ . Podsumowując, pochodna po  $b_i$  z funkcji  $\|Y - \mathbb{X}b\|_2^2$  jest równa przeskalowanemu (-2) iloczynowi skalarnemu pomiędzy kolumną związaną z  $i$ -tym współczynnikiem w wektorze  $b$  a wektorem residuów  $e(b)$ :

$$\partial_{b_i} \|Y - \mathbb{X}b\|_2^2 = -2\mathbb{X}'_{\bullet i}(Y - \mathbb{X}b)$$

Zapis wykorzystujący gradient funkcji ( $\nabla_s f(s) = (\partial_{s_1} f(s), \dots, \partial_{s_d} f(s))'$ ) umożliwia uzyskanie jeszcze bardziej zwartej postaci:

Gradient funkcji  $\|Y - \mathbb{X}b\|_2^2$

$$\nabla_b \|Y - \mathbb{X}b\|_2^2 = -2\mathbb{X}'(Y - \mathbb{X}b)$$

# Estymator metody najmniejszych kwadratów (3)

Wykonując dalsze przekształcenia łatwo jest wyznaczyć hesjan funkcji  $\|Y - \mathbb{X}b\|_2^2$ :

$$\begin{aligned}Hes_{jk} &= \partial_{b_{k-1}}(\partial_{b_{j-1}}\|Y - \mathbb{X}b\|_2^2) = \\&= \partial_{b_{k-1}} \sum_{i=1}^n -2\mathbb{X}_{ij}(Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1})) = \\&= \sum_{i=1}^n 2\mathbb{X}_{ij}\mathbb{X}_{ik} = 2(\mathbb{X}'\mathbb{X})_{jk}\end{aligned}$$

Zatem hesjan funkcji  $\|Y - \mathbb{X}b\|_2^2$  w macierzowej postaci ma formę:

Hesjan funkcji  $\|Y - \mathbb{X}b\|_2^2$

$$Hes = 2\mathbb{X}'\mathbb{X}$$

## Estymator metody najmniejszych kwadratów (4)

Łatwo pokazać, że hesjan  $Hes = 2\mathbb{X}'\mathbb{X}$  jest dodatnio określony:

Niech  $v \in \mathbb{R}^n$  będzie dowolnym niezerowym wektorem. Wówczas

$$v'(Hes)v = 2v'\mathbb{X}'\mathbb{X}v = 2(\mathbb{X}v)'(\mathbb{X}v) = 2\|\mathbb{X}v\|_2^2 \geq 0$$

W konsekwencji, ekstremum wyznaczone za pomocą przyrównania gradientu do zera musi być minimum dla funkcji  $\|Y - \mathbb{X}b\|_2^2$  i stanowi estymator OLS:

$$-2\mathbb{X}'(Y - \mathbb{X}\hat{\beta}) = 0 \quad \Leftrightarrow \quad \mathbb{X}'\mathbb{X}\hat{\beta} = \mathbb{X}'Y$$

Ostatecznie uzyskujemy:

### Estymator metody najmniejszych kwadratów

Założmy, że macierz  $\mathbb{X}'\mathbb{X}$  jest odwracalna ( $\det(\mathbb{X}'\mathbb{X}) \neq 0$ ). Wówczas estymator metody najmniejszych kwadratów ma postać:

$$\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y$$

Uwaga!

Można pokazać, że założenie o odwracalności macierzy  $\mathbb{X}'\mathbb{X}$  jest równoważne liniowej niezależności kolumn macierzy  $\mathbb{X}$ .

W wielu sytuacjach jest to naturalny warunek w kontekście modeli liniowych i od tej pory na wykładzie będzie on zakładany.

# Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi  $Y_1, \dots, Y_n$ :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left( -\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

# Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi  $Y_1, \dots, Y_n$ :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left( -\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

Logarytm funkcji wiarygodności:

$$\log(L(b, z^2 | Y)) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log z^2 - \frac{1}{2z^2} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

# Estymator metody największej wiarygodności (MLE)

Aby wyznaczyć estymator największej wiarygodności musimy znaleźć wektor maksymalizujący funkcję wiarygodności dla zbioru zmiennych odpowiedzi  $Y_1, \dots, Y_n$ :

$$L(b, z^2 | Y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi z^2}} \exp \left( -\frac{1}{2z^2} (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2 \right)$$

Logarytm funkcji wiarygodności:

$$\log(L(b, z^2 | Y)) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log z^2 - \frac{1}{2z^2} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

Z powyższej postaci widać, że dla dowolne wartości  $z^2$ , maksymalizacja po wektorze  $b$  jest równoważna minimalizacji wyrażenia:

$$\sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}b_0 + \mathbb{X}_{i2}b_1 + \dots + \mathbb{X}_{ip}b_{p-1}))^2$$

czyli minimalizacji sumy kwadratów residuów. Wynika stąd, że estymatory  $\hat{\beta}$  uzyskane metodami ML i OLS są takie same.

# Metoda największej wiarygodności (Maximum Likelihood)

Aby wyznaczyć estymator ML dla  $\sigma^2$  musimy policzyć pochodną z logarytmu funkcji wiarygodności po  $z^2$  i przyrównać do 0 (ekstremum) oraz sprawdzić, że rozwiązanie faktycznie maksymalizuje badaną funkcję. Estimator ML jest postaci:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}\hat{\beta}_0 + \mathbb{X}_{i2}\hat{\beta}_1 + \dots + \mathbb{X}_{ip}\hat{\beta}_{p-1}))^2$$

Można pokazać, że jest on obciążony. Nieobciążony estymator (zwykle stosowany) ma postać:

$$s^2 = \frac{1}{n-p} \sum_{i=1}^n (Y_i - (\mathbb{X}_{i1}\hat{\beta}_0 + \mathbb{X}_{i2}\hat{\beta}_1 + \dots + \mathbb{X}_{ip}\hat{\beta}_{p-1}))^2 = \frac{1}{n-p} \|Y - \mathbb{X}\hat{\beta}\|_2^2$$

$$E(s^2) = \sigma^2$$



Znając estymator  $\hat{\beta}$  w łatwy sposób możemy wyznaczyć przewidywane wartości zmiennej objaśnianej dla wartości ze zbioru danych

$Y = (Y_1, \dots, Y_n)$ :

$$\hat{Y} = X\hat{\beta}$$

Znając estymator  $\hat{\beta}$  w łatwy sposób możemy wyznaczyć przewidywane wartości zmiennej objaśnianej dla wartości ze zbioru danych

$Y = (Y_1, \dots, Y_n)$ :

$$\hat{Y} = X\hat{\beta}$$

W analogiczny sposób możemy dokonać predykcji dla dowolnej wartości  $Y \in \mathbb{R}$ .

Założmy że chcemy znaleźć przewidywaną wartość zmiennej objaśnianej  $\tilde{Y}$  dla wektora wartości zmiennych objaśniających  $\tilde{X} = (1, \tilde{X}_1, \dots, \tilde{X}_{p-1})$  (np. nowy wiersz w macierzy planu) na podstawie skonstruowanego modelu empirycznego. Wówczas:

$$\hat{\tilde{Y}} = \tilde{X}\hat{\beta}$$

# Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne

## Rozkład estymatora $\hat{\beta}$

Estymator otrzymany metodą najmniejszych kwadratów ma następujący rozkład:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbb{X}'\mathbb{X})^{-1})$$

- normalność wynika z faktu, że  $\hat{\beta} = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y$  jest liniowym przekształceniem wektora  $Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$ ,

- wartość oczekiwana:

$$E(\hat{\beta}) = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'E(Y) = (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}\beta = \beta \text{ (estymator jest nieobciążony),}$$

- macierz kowariancji:

$$\begin{aligned} \text{Cov}(\hat{\beta}) &= (\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\sigma^2\mathbb{I}((\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')' = \\ &= \sigma^2(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}((\mathbb{X}'\mathbb{X})^{-1})' = \sigma^2((\mathbb{X}'\mathbb{X})')^{-1} = \sigma^2(\mathbb{X}'\mathbb{X})^{-1} \end{aligned}$$

W dowodzie postaci macierzy kowariancji korzystaliśmy z własności macierzy:  $(AB)' = B'A'$  oraz  $(A^{-1})' = (A')^{-1}$

# Macierz H

Wprowadźmy następujące oznaczenie na macierz

$$H = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'$$

Macierz H jest ważnym obiektem w analizie modeli liniowych. Przy jej pomocy można w łatwy sposób wyrazić predykcję wektora odpowiedzi  $\hat{Y}$  i wektor residuów  $e$ :

Predykcja  $\hat{Y}$  i residua wyrażone przy pomocy macierzy H

$$\hat{Y} = \mathbb{X}\hat{\beta} = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'Y = HY$$

$$e = Y - \hat{Y} = (\mathbb{I} - H)Y$$

Kolejną ważną własnością macierzy H jest:

H – macierz rzutu ortogonalnego na  $Lin(\mathbb{X})$

Macierz H jest macierzą rzutu ortogonalnego na przestrzeń  $Lin(\mathbb{X})$  rozpiętą na kolumnach macierzy eksperymentu.

Aby to wykazać skorzystamy z charakteryzacji rzutów ortogonalnych z algebry liniowej:

dowolna macierz  $P$  jest macierzą rzutu ortogonalnego wtedy i tylko wtedy gdy macierz  $P$  jest symetryczna ( $P = P'$ ) i idempotentna ( $P^2 = P$ ).

Aby to wykazać skorzystamy z charakteryzacji rzutów ortogonalnych z algebry liniowej:

dowolna macierz  $P$  jest macierzą rzutu ortogonalnego wtedy i tylko wtedy gdy macierz  $P$  jest symetryczna ( $P = P'$ ) i idempotentna ( $P^2 = P$ ).

Łatwo pokazać, że macierz  $H$  ma obie powyższe cechy:

- symetryczność:  $H' = (\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')' = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = H$

- idempotentność:

$$H^2 = (\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}')(\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}') = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}' = H$$

Pozostaje wykazać że przestrzeń na którą rzutuje macierz  $H$  to  $\text{Lin}(\mathbb{X})$ .

Rozważmy dowolny wektor  $v \in \mathbb{R}^n$  i rozłóżmy go na dwie składowe  $v = v_1 + v_2$ , w taki sposób że  $v_1 \in \text{Lin}(\mathbb{X})$ , a  $v_2 \perp \text{Lin}(\mathbb{X})$ . Ponieważ  $v_1$  należy do przestrzeni  $\text{Lin}(\mathbb{X})$  zatem możemy go wyrazić jako kombinację liniową kolumn z macierzy  $\mathbb{X}$ :

$$v_1 = \mathbb{X}w$$

gdzie  $w \in \mathbb{R}^p$ . Z drugiej strony ze względu na to, że wektor  $v_2$  należy do przestrzeni ortogonalnej do  $\text{Lin}(\mathbb{X})$ , otrzymujemy że dla dowolnej kolumny w macierzy  $\mathbb{X}$ , iloczyn skalarny pomiędzy tą kolumną a wektorem  $v_2$  wynosi zero. Stąd:

$$\mathbb{X}'v_2 = 0$$

Wykorzystując otrzymane relacje otrzymujemy:

$$Hv = Hv_1 + Hv_2 = \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}w + \mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'v_2 = \mathbb{X}w = v_1$$

Wobec założonej dowolności wektora  $v$ , uzyskujemy ostatecznie, że macierz  $H$  rzutuje na przestrzeń rozpiętą przez kolumny macierzy  $\mathbb{X}$ .



# Rozkłady $\hat{Y}$ oraz $e$

Łatwo pokazać (przez analogiczne przekształcenia), że macierz  $\mathbb{I} - H$  jest macierzą rzutu ortogonalnego na przestrzeń ortogonalną do  $Lin(\mathbb{X})$ . W konsekwencji otrzymujemy, że predykcja  $\hat{Y}$  oraz wektor residuów  $e$  dane wzorami:

$$\hat{Y} = HY; \quad e = (\mathbb{I} - H)Y$$

są rozkładem wektora  $Y$  na dwie ortogonalne składowe: leżącą w przestrzeni  $Lin(\mathbb{X})$  (wekt.  $\hat{Y}$ ) i w przestrzeni ortogonalnej do niej (wekt.  $e$ ).

## Rozkłady $\hat{Y}$ oraz $e$

Łatwo pokazać (przez analogiczne przekształcenia), że macierz  $\mathbb{I} - H$  jest macierzą rzutu ortogonalnego na przestrzeń ortogonalną do  $\text{Lin}(\mathbb{X})$ . W konsekwencji otrzymujemy, że predykcja  $\hat{Y}$  oraz wektor residuów  $e$  dane wzorami:

$$\hat{Y} = HY; \quad e = (\mathbb{I} - H)Y$$

są rozkładem wektora  $Y$  na dwie ortogonalne składowe: leżącą w przestrzeni  $\text{Lin}(\mathbb{X})$  (wekt.  $\hat{Y}$ ) i w przestrzeni ortogonalnej do niej (wekt.  $e$ ).

Korzystając z powyższych wzorów oraz z faktu że  $Y \sim N(\mathbb{X}\beta, \sigma^2\mathbb{I})$ , w natychmiastowy sposób otrzymujemy rozkłady obu wektorów:

## Rozkłady $\hat{Y}$ oraz $e$

Predykcja  $\hat{Y}$  oraz wektor residuów  $e$  mają następujące rozkłady:

$$\hat{Y} \sim N(\mathbb{X}\beta, \sigma^2 H); \quad e \sim N(0, \sigma^2(\mathbb{I} - H))$$

Na mocy powyższej zależności łatwo zauważyć, że elementy wektora  $e$  są skorelowane! (inaczej niż elementy wektora błędów losowych  $\epsilon$ ).

# Rozkład estymatora $s^2$

Przypomnijmy, że estymator wariancji błędów losowych  $s^2$  jest funkcją wektora residuów  $e$  i dany jest wzorem:

$$s^2 = \frac{1}{n-p} \|e\|_2^2$$

Można pokazać natępującą własność estymatora  $s^2$ :

## Rozkład estymatora $s^2$

Jeżeli wyrazimy estymator  $s^2$  w następujący sposób:

$$s^2 = \sigma^2 \frac{K}{n-p}$$

Wówczas  $K$  jest zmienną losową z rozkładu  $\chi^2$  z  $n-p$  stopniami swobody. Wykorzystując zależność pomiędzy  $s^2$  i  $e$  otrzymujemy:

$$K = \left\| \frac{e}{\sigma} \right\|_2^2 \sim \chi_{n-p}^2$$

# Rozkład estymatora $s^2$

## dowód

Pokażemy, że  $\|e/\sigma\|_2^2 \sim \chi_{n-p}^2$ . W pierwszym kroku zauważmy, iż

$$e = (\mathbb{I} - H)Y = (\mathbb{I} - H)(\mathbb{X}\beta + \epsilon) = (\mathbb{I} - H)\epsilon$$

Niech  $(\mathbb{I} - H) = Q\Lambda Q'$  będzie diagonalizacją macierzy.

$Q$  – macierz wekt. własnych,  $QQ' = Q'Q = \mathbb{I}$  (izometria),

$\Lambda$  – macierz diagonalna o wartościach własnych  $\lambda_i$  macierzy  $(\mathbb{I} - H)$  na diagonalu.

Wykorzystując powyższy rozkład macierzy  $(\mathbb{I} - H)$ , otrzymujemy

$$\|e/\sigma\|_2^2 = \|(\mathbb{I} - H)\epsilon/\sigma\|_2^2 = \|Q(\Lambda Q'\epsilon/\sigma)\|_2^2 = (\Lambda Q'\epsilon/\sigma)' Q'Q(\Lambda Q'\epsilon/\sigma) = \|\Lambda Q'\epsilon/\sigma\|_2^2$$

W ostatnim kroku skorzystaliśmy z faktu że macierz  $Q$  jest izometrią (nie zmienia długości wektorów).

Wprowadźmy następujące oznaczenie na wektor  $Z = Q'\epsilon/\sigma$ . Zauważmy, że wektor  $Z$  pochodzi z wielowymiarowego standardowego rozkładu normalnego:

$$Z = (Q'/\sigma)\epsilon \sim N(0, (Q'/\sigma)\sigma^2\mathbb{I}(Q'/\sigma)') = N(0, Q'Q) = N(0, \mathbb{I})$$

Otrzymujemy zatem, że badane wyrażenie jest ważoną sumą kwadratów niezależnych zmiennych losowych ze standardowego rozkładu normalnego:

$$\|e/\sigma\|_2^2 = \|\Lambda Q'\epsilon/\sigma\|_2^2 = \|\Lambda Z\|_2^2 = \sum_{i=1}^n \lambda_i^2 Z_i^2$$

# Rozkład estymatora $s^2$

Pozostaje zbadać własności wartości własnych  $\lambda_i$  ( $\|e/\sigma\|_2^2 = \sum_{i=1}^n \lambda_i^2 Z_i^2$ ). Fakt, iż macierz  $(\mathbb{I} - H)$  jest macierzą rzutu ortogonalnego implikuje że jej wartości własne  $\lambda_i$  muszą być równe 0 lub 1.

Niech  $P$  – rzut ort. Ponieważ  $P^2 = P$  zatem dla dowolnego wektora własnego  $v_i$  i stowarzyszonej z nim wartości własnej  $\lambda_i$  mamy  $\lambda_i v_i = P v_i = (PP)v_i = P(Pv_i) = P(\lambda_i v_i) = \lambda_i (Pv_i) = \lambda_i^2 v_i$ , stąd  $\lambda_i^2 v_i - \lambda_i v_i = 0 \Rightarrow \lambda_i(\lambda_i - 1) = 0 \Rightarrow \lambda_i \in \{0, 1\}$

Korzystając z własności, że ślad z macierzy jest równy sumie jej wartości własnych, możemy wyznaczyć liczbę wartości własnych równych 1 w  $(\mathbb{I} - H)$ :

$$\begin{aligned} \sum_{i=1}^n \lambda_i &= \text{Tr}(\mathbb{I} - H) = \text{Tr}(\mathbb{I}_{n \times n}) - \text{Tr}(H) = n - \text{Tr}(\mathbb{X}(\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}') = \\ &= n - \text{Tr}((\mathbb{X}'\mathbb{X})^{-1}\mathbb{X}'\mathbb{X}) = n - \text{Tr}(\mathbb{I}_{p \times p}) = n - p \end{aligned}$$

gdzie między pierwszą a drugą linią skorzystaliśmy z cykliczności śladu macierzy  $\text{Tr}(ABC) = \text{Tr}(BCA)$

Ostatecznie uzyskujemy że  $n - p$  wartości własnych jest równa 1 oraz  $p$  jest równa 0. W konsekwencji:

$$\|e/\sigma\|_2^2 = \sum_{i=1}^n \lambda_i^2 Z_i^2 = \sum_{\{i: \lambda_i=1\}} 1 * Z_i^2 + \sum_{\{i: \lambda_i=0\}} 0 * Z_i^2 = \sum_{\{i: \lambda_i=1\}} Z_i^2 \sim \chi_{n-p}^2$$

# Table of Contents

- 1 Regresja liniowa wieloraka
- 2 Teoretyczny model – zapis macierzowy
- 3 Metody estymacji
- 4 Własności teoretyczne estymatorów
- 5 Wnioskowanie statystyczne

# Testowanie dotyczące wektora parametrów $\beta$

Poznaliśmy już własności estymatorów  $\hat{\beta}$  i  $s^2$ :

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbb{X}'\mathbb{X})^{-1}); \quad s^2 = \frac{1}{n-p} \|e\|_2^2$$

Przy ich pomocy możemy testować istotność dowolnej kombinacji liniowej elementów wektora parametrów  $\beta$ . Niech  $c = (c_0, \dots, c_{p-1})' \in \mathbb{R}^p$  i  $d \in \mathbb{R}$ .

Wówczas:

$$H_0 : c'\beta - d = 0 \quad \text{vs} \quad H_1 : c'\beta - d \neq 0$$

Statystyka testowa dla powyższego zagadnienia ma postać:

$$T = \frac{c'\hat{\beta} - d}{s(c'\hat{\beta})} \quad \text{gdzie} \quad s^2(c'\hat{\beta}) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1} c$$

Statystyka  $T$  przy założeniu prawdziwości hipotezy  $H_0$ , ma rozkład studenta z  $n - p$  stopniami swobody. W konsekwencji będziemy odrzucać  $H_0$  na poziomie istotności  $\alpha$ , jeżeli  $|T| > t_c$  gdzie  $t_c = t^*(1 - \alpha/2, n - p)$  jest kwantylem rzędu  $1 - \alpha/2$  z rozkładu studenta z  $n - p$  stopniami swobody.

p-wartość dla tego problemu:

$p = P(|z| > |T|) = 2(1 - F_z(|T|))$ , gdzie  $z \sim t(n - p)$  i  $F_z$  – dystrybuanta zmiennej los.  $z$ .

# Ważne przykłady

Do czego nam się przydaje taki "egzotyczny" test?



# Ważne przykłady

Do czego nam się przydaje taki "egzotyczny" test?

Przy jego pomocy unifikujemy kilka poznanych wcześniej testów:

Do czego nam się przydaje taki "egzotyczny" test?

Przy jego pomocy unifikujemy kilka poznanych wcześniej testów:

Przykład 1 (Testowanie istotności parametru  $\beta_i$ )

Jeżeli  $c = (0, \dots, 0, 1, 0, \dots, 0)'$ , gdzie wartość 1 odpowiada parametrowi  $\beta_i$  oraz  $d = 0$ . Wówczas  $c'\beta - d = \beta_i$  i zagadnienie testowe sprowadza się do postaci:

$$H_0 : \beta_i = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0$$

a statystyka testowa ma postać:

$$T_i = \frac{\hat{\beta}_i}{s(\hat{\beta}_i)} \quad \text{gdzie} \quad s^2(\hat{\beta}_i) = s^2(\mathbb{X}'\mathbb{X})_{i+1,i+1}^{-1}$$

## Przykład 2 (Testowanie dotyczące $E(\tilde{Y}_h)$ )

Jeżeli chcemy przeprowadzić testowanie dotyczące wartości oczekiwanej ze zmiennej objaśnianej  $E(\tilde{Y}_h) = \tilde{\mathbf{X}}_h \beta = \tilde{\mu}_h$  wystarczy, że za wektor  $c$  wstawimy ciąg wartości zmiennych objaśniających stowarzyszonych z  $\tilde{Y}_h$ ,  $c = (1, \tilde{X}_{h1}, \dots, \tilde{X}_{hp-1})' = \tilde{\mathbf{X}}_h'$ . Wówczas  $c'\beta - d = \tilde{\mu}_h - d$  i zagadnienie testowe sprowadza się do postaci:

$$H_0 : \tilde{\mu}_h - d = 0 \quad \text{vs} \quad H_1 : \tilde{\mu}_h - d \neq 0$$

a statystyka testowa ma postać:

$$T = \frac{\hat{\tilde{\mu}}_h - d}{s(\hat{\tilde{\mu}}_h)} \quad \text{gdzie} \quad \hat{\tilde{\mu}}_h = \tilde{\mathbf{X}}_h \hat{\beta} \quad \text{i} \quad s^2(\hat{\tilde{\mu}}_h) = s^2 \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h'$$

# Uzasadnienie rozkładu statystyki $T$

Dla regresji liniowej prostej fakt opisujący rozkład statystyki  $T$  został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

# Uzasadnienie rozkładu statystyki $T$

Dla regresji liniowej prostej fakt opisujący rozkład statystyki  $T$  został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

Z definicji zmienną losową z rozkładu studenta o  $k$  stopniach swobody można wyrazić jako iloraz niezależnych zmiennych losowych:  $\tilde{T} = \frac{\tilde{Z}}{\sqrt{\tilde{K}/k}}$  ma rozkład stud. z  $k$  st. swob. gdy  $\tilde{Z} \sim N(0, 1)$ ;  $\tilde{K} \sim \chi_k^2$ ;  $\tilde{Z} \perp \tilde{K}$

Statystykę  $T$  możemy wyrazić w następujący sposób:

$$T = \frac{c' \hat{\beta} - d}{\sqrt{s^2 c' (\mathbb{X}' \mathbb{X})^{-1} c}} = \frac{(c' \hat{\beta} - d) / \left( \sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right)}{\sqrt{s^2 / \sigma^2}}$$

Zauważmy, że przy  $H_0$  licznik i mianownik mają odpowiednie rozkłady:

$$c' \hat{\beta} \sim N(d, \sigma^2 c' (\mathbb{X}' \mathbb{X})^{-1} c) \Rightarrow (c' \hat{\beta} - d) / \left( \sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right) \sim N(0, 1)$$

$$s^2 / \sigma^2 = \frac{1}{n-p} \left\| \frac{\mathbf{e}}{\sigma} \right\|_2^2 \text{ oraz } \left\| \frac{\mathbf{e}}{\sigma} \right\|_2^2 = K \sim \chi_{n-p}^2$$

# Uzasadnienie rozkładu statystyki $T$

Dla regresji liniowej prostej fakt opisujący rozkład statystyki  $T$  został podany bez uzasadnienia. Obecnie pokażemy go, w ścisły sposób.

Z definicji zmienną losową z rozkładu studenta o  $k$  stopniach swobody można wyrazić jako iloraz niezależnych zmiennych losowych:  $\tilde{T} = \frac{\tilde{Z}}{\sqrt{\tilde{K}/k}}$  ma rozkład stud. z  $k$  st. swob. gdy  $\tilde{Z} \sim N(0, 1)$ ;  $\tilde{K} \sim \chi_k^2$ ;  $\tilde{Z} \perp \tilde{K}$

Statystykę  $T$  możemy wyrazić w następujący sposób:

$$T = \frac{c' \hat{\beta} - d}{\sqrt{s^2 c' (\mathbb{X}' \mathbb{X})^{-1} c}} = \frac{(c' \hat{\beta} - d) / \left( \sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right)}{\sqrt{s^2 / \sigma^2}}$$

Zauważmy, że przy  $H_0$  licznik i mianownik mają odpowiednie rozkłady:

$$c' \hat{\beta} \sim N(d, \sigma^2 c' (\mathbb{X}' \mathbb{X})^{-1} c) \Rightarrow (c' \hat{\beta} - d) / \left( \sigma \sqrt{c' (\mathbb{X}' \mathbb{X})^{-1} c} \right) \sim N(0, 1)$$

$$s^2 / \sigma^2 = \frac{1}{n-p} \left\| \frac{e}{\sigma} \right\|_2^2 \text{ oraz } \left\| \frac{e}{\sigma} \right\|_2^2 = K \sim \chi_{n-p}^2$$

Pozostaje zbadać niezależność. W tym celu wystarczy pokazać niezależność  $\hat{\beta}$  i  $e$ :

$$\begin{aligned} \text{Cov}(e, \hat{\beta}) &= \text{Cov}((\mathbb{I} - H)Y, (\mathbb{X}' \mathbb{X})^{-1} \mathbb{X}' Y) = (\mathbb{I} - H) \text{Cov}(Y, Y) \mathbb{X} (\mathbb{X}' \mathbb{X})^{-1} = \\ &= (\mathbb{I} - H)(\sigma^2 \mathbb{I}) \mathbb{X} (\mathbb{X}' \mathbb{X})^{-1} = \sigma^2 (\mathbb{X} - H\mathbb{X})(\mathbb{X}' \mathbb{X})^{-1} = 0 \end{aligned}$$

Wektory  $\hat{\beta}$  i  $e$  są nieskorelowane i mają normalne rozkłady (jako przekształt. wekt.  $Y$ ), stąd są również niezależne. Dodatkowo, własność ta jest dziedziczona na licznik i mianownik jako przekształcenia odpowiednich wektorów (licznik =  $f_1(\hat{\beta})$ ; mianownik =  $f_2(e)$ ).

# Przedziały ufności

Na podstawie statystyki  $T$  możemy również skonstruować przedział ufności o współczynniku ufności  $1 - \alpha$  dla kombinacji liniowej  $c'\beta$ :

$$c'\hat{\beta} \pm t_c s(c'\hat{\beta})$$

gdzie  $s^2(c'\hat{\beta}) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1}c$  oraz  $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$  jest kwantylem rzędu  $1 - \frac{\alpha}{2}$  z rozkładu studenta z  $n - p$  stopniami swobody.

# Przedziały ufności

Na podstawie statystyki  $T$  możemy również skonstruować przedział ufności o współczynniku ufności  $1 - \alpha$  dla kombinacji liniowej  $c'\beta$ :

$$c'\hat{\beta} \pm t_c s(c'\hat{\beta})$$

gdzie  $s^2(c'\hat{\beta}) = s^2 c'(\mathbb{X}'\mathbb{X})^{-1}c$  oraz  $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$  jest kwantylem rzędu  $1 - \frac{\alpha}{2}$  z rozkładu studenta z  $n - p$  stopniami swobody.

Przykład 1 (przedział ufności dla parametru  $\beta_i$ ;  $c = (0, \dots, 0, 1, 0, \dots, 0)'$ ):

$$\hat{\beta}_i \pm t_c s(\hat{\beta}_i) \text{ gdzie } s^2(\hat{\beta}_i) = s^2(\mathbb{X}'\mathbb{X})_{i+1,i+1}^{-1}$$

Przykład 2 (przedział ufności dla  $\tilde{\mu}_h$ ;  $c = (1, \tilde{X}_{h1}, \dots, \tilde{X}_{hp-1})' = \tilde{\mathbb{X}}_h'$ ):

$$\hat{\mu}_h \pm t_c s(\hat{\mu}_h) \text{ gdzie } \hat{\mu}_h = \tilde{\mathbb{X}}_h' \hat{\beta} \text{ i } s^2(\hat{\mu}_h) = s^2 \tilde{\mathbb{X}}_h' (\mathbb{X}'\mathbb{X})^{-1} \tilde{\mathbb{X}}_h.$$



# Przedział predykcyjny dla nowej obserwacji $\tilde{Y}_h$

Wykonując podobne rozumowanie możemy wyznaczyć przedział predykcyjny na poziomie  $1 - \alpha$  dla nowej obserwacji  $\tilde{Y}_h$ . Jest on postaci:

$$\hat{\mu}_h \pm t_c s(pred) \quad \text{gdzie} \quad \hat{\mu}_h = \tilde{\mathbf{X}}_h \hat{\boldsymbol{\beta}} \quad \text{i} \quad s^2(pred) = s^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

gdzie  $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$  jest kwantylem rzędu  $1 - \frac{\alpha}{2}$  z rozkładu studenta z  $n - p$  stopniami swobody.

# Przedział predykcyjny dla nowej obserwacji $\tilde{Y}_h$

Wykonując podobne rozumowanie możemy wyznaczyć przedział predykcyjny na poziomie  $1 - \alpha$  dla nowej obserwacji  $\tilde{Y}_h$ . Jest on postaci:

$$\hat{\mu}_h \pm t_c s(pred) \quad \text{gdzie} \quad \hat{\mu}_h = \tilde{\mathbf{X}}_h \hat{\beta} \quad \text{i} \quad s^2(pred) = s^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

gdzie  $t_c = t^*(1 - \frac{\alpha}{2}, n - p)$  jest kwantylem rzędu  $1 - \frac{\alpha}{2}$  z rozkładu studenta z  $n - p$  stopniami swobody.

szkic dowodu

Chcemy pokazać że:

$$P(\hat{\mu}_h - t_c s(pred) < \tilde{Y}_h < \hat{\mu}_h + t_c s(pred)) = 1 - \alpha$$

Łatwo pokazać że:

$$P(\hat{\mu}_h - t_c s(pred) < \tilde{Y}_h < \hat{\mu}_h + t_c s(pred)) = P\left(\left|\frac{\tilde{Y}_h - \hat{\mu}_h}{s(pred)}\right| < t_c\right)$$

Wiemy, że zmienna losowa  $\tilde{Y}_h$  ma rozkład  $N(\tilde{\mathbf{X}}_h \beta, \sigma^2)$  i jako nowa obserwacja jest niezależna od  $\hat{\mu}_h \sim N(\tilde{\mathbf{X}}_h \beta, \sigma^2 \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$ . Stąd:

$$E(\tilde{Y}_h - \hat{\mu}_h) = 0$$

$$\sigma^2(pred) = \text{var}(\tilde{Y}_h - \hat{\mu}_h) = \text{var}(\tilde{Y}_h) + \text{var}(\hat{\mu}_h) = \sigma^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')$$

Łatwo zauważyć, że  $s^2(pred)$  jest estymatorem  $\sigma^2(pred)$ . Ponadto jest on zmienną losową niezależną od  $\tilde{Y}_h - \hat{\mu}_h$  ( $\hat{\mu}_h$  jest funkcją  $\hat{\beta}$  a  $\tilde{Y}_h$  jest nową niezależną obserwacją). Zatem:

$$\frac{\tilde{Y}_h - \hat{\mu}_h}{s(pred)} = \frac{(\tilde{Y}_h - \hat{\mu}_h) / \sqrt{\sigma^2(1 + \tilde{\mathbf{X}}_h (\mathbf{X}'\mathbf{X})^{-1} \tilde{\mathbf{X}}_h')}}{\sqrt{\frac{s^2}{\sigma^2}}} \sim N(0, 1) \\ \sim \sqrt{\chi_{n-p}^2 / (n-p)}$$